

Rapport de Projet

Galaxy-GAN

Génération d'images de galaxies par réseau antagoniste génératif
conditionnel

Projet d'Intelligence Artificielle Générative

11 mai 2026

Résumé

Ce rapport présente le développement d'un **GAN conditionnel (cGAN)** basé sur l'architecture **WGAN-GP** (Wasserstein GAN avec Gradient Penalty) pour la génération d'images synthétiques de galaxies. L'objectif est d'apprendre la distribution visuelle de différents types morphologiques de galaxies et d'en générer de nouvelles, conditionnées par leur classe morphologique.

Table des matières

1	Introduction	3
2	Dataset	3
2.1	Source et composition	3
2.2	Prétraitement	3
3	Architecture du modèle	3
3.1	Générateur	3
3.2	Discriminateur	3
4	Entraînement	4
4.1	Fonction de perte — WGAN-GP	4
4.1.1	Perte du discriminateur	4
4.1.2	Perte du générateur	4
4.1.3	Gradient Penalty	4
4.2	Hyperparamètres	4
4.3	Procédure d'entraînement	5
4.4	Gestion des checkpoints	5

5	Résultats et observations	5
5.1	Évolution des pertes	5
5.2	Interprétation des pertes	5
5.3	Résultats visuels	5
6	Difficultés rencontrées	6
7	Pistes d'amélioration	7
7.1	Stabilisation de l'entraînement	7
7.2	Amélioration de la qualité	7
7.3	Évaluation quantitative	7
7.4	Données	7
8	Conclusion	7

1 Introduction

La génération d'images astronomiques synthétiques représente un enjeu important pour l'augmentation de données dans les tâches de classification morphologique de galaxies. Les **Generative Adversarial Networks (GANs)**, constituent une approche puissante pour ce type de tâche.

Ce projet implémente un **cGAN conditionnel** utilisant la distance de Wasserstein avec pénalité de gradient (WGAN-GP), permettant une génération contrôlée par type morphologique. Le modèle est entraîné sur un dataset de galaxies réelles et évalué visuellement sur 4 classes distinctes.

2 Dataset

2.1 Source et composition

Les images proviennent de catalogues astronomiques (de type Galaxy Zoo), couvrant 4 types morphologiques de galaxies :

- Classe 0** : galaxies elliptiques
- Classe 1** : galaxies spirales
- Classe 2** : galaxies spirales barrées
- Classe 3** : galaxies irrégulières / autres

2.2 Prétraitement

Le pipeline de prétraitement comprend :

- Redimensionnement des images en 64×64 pixels
- Normalisation des valeurs de pixels dans $[-1, 1]$
- Encodage des labels en entiers longs (`torch.long`)
- Sauvegarde au format NumPy (`.npy`)

Les données sont chargées via deux fichiers : `train_images.npy` et `train_labels.npy`.

3 Architecture du modèle

3.1 Générateur

Le générateur $G : \mathbb{R}^Z \times \mathcal{C} \rightarrow \mathbb{R}^{3 \times 64 \times 64}$ prend en entrée un vecteur de bruit latent et un label de classe :

- **Entrée** : vecteur latent $\mathbf{z} \sim \mathcal{N}(0, I)$ de dimension 100
- **Conditionnement** : embedding de classe de dimension 50, concaténé à $\mathbf{z}$
- **Architecture** : couches `ConvTranspose2d` avec `BatchNorm2d` et activations `ReLU`
- **Sortie** : image RGB 64×64 avec activation `tanh`

3.2 Discriminateur

Le discriminateur $D : \mathbb{R}^{3 \times 64 \times 64} \times \mathcal{C} \rightarrow \mathbb{R}$ produit un score scalaire réel :

- **Entrée** : image + embedding de classe projeté

- **Architecture** : couches Conv2d avec LeakyReLU, **sans** BatchNorm (requis par WGAN-GP)
- **Sortie** : score scalaire (sans sigmoïde)

L'absence de BatchNorm dans le discriminateur est une contrainte fondamentale de WGAN-GP pour garantir la condition de Lipschitz via le gradient penalty.

4 Entraînement

4.1 Fonction de perte — WGAN-GP

Le WGAN-GP remplace la divergence de Jensen-Shannon par la **distance de Wasserstein-1**, offrant une meilleure stabilité d'entraînement et des gradients plus informatifs.

4.1.1 Perte du discriminateur

$$\mathcal{L}_D = \underbrace{\mathbb{E}_{\tilde{x} \sim P_g} [D(\tilde{x})] - \mathbb{E}_{x \sim P_r} [D(x)]}_{\text{distance de Wasserstein}} + \lambda \cdot GP \quad (1)$$

4.1.2 Perte du générateur

$$\mathcal{L}_G = -\mathbb{E}_{\tilde{x} \sim P_g} [D(\tilde{x})] \quad (2)$$

4.1.3 Gradient Penalty

La pénalité de gradient est calculée sur des points interpolés $\hat{x} = \epsilon x + (1 - \epsilon)\tilde{x}$, avec $\epsilon \sim \mathcal{U}(0, 1)$:

$$GP = \mathbb{E}_{\hat{x}} [(\|\nabla_{\hat{x}} D(\hat{x})\|_2 - 1)^2] \quad (3)$$

Cette pénalité force le discriminateur à satisfaire la contrainte 1-Lipschitz, condition nécessaire pour l'estimation de la distance de Wasserstein.

4.2 Hyperparamètres

TABLE 1 – Hyperparamètres d'entraînement

Paramètre	Valeur	Description
Z_DIM	100	Dimension du bruit latent
EMBED_DIM	50	Dimension de l'embedding de classe
BATCH_SIZE	64	Taille des batches
LR	1e-4 et 5e-5	Taux d'apprentissage avant et après 200 epochs
BETAS	(0.0, 0.9)	Moments Adam (recommandé WGAN)
N_CRITIC	3	Mises à jour D par mise à jour G
LAMBDA_GP	5	Coefficient du gradient penalty
EPOCHS	200 + 100	Nombre total d'epochs
NUM_CLASSES	4	Nombre de classes morphologiques

4.3 Procédure d'entraînement

Pour chaque batch :

1. **Mise à jour du discriminateur** ($\times N_CRITIC$) :
 - Générer des fausses images avec G
 - Calculer $\mathcal{L}_D$ (éq. 1) incluant le GP
 - Rétropropagation et mise à jour de D
2. **Mise à jour du générateur** ($\times 1$) :
 - Générer de nouvelles fausses images
 - Calculer $\mathcal{L}_G$ (éq. 2)
 - Rétropropagation et mise à jour de G

4.4 Gestion des checkpoints

Le système de reprise (*resume*) permet de relancer l'entraînement depuis n'importe quel checkpoint :

- Sauvegarde tous les 10 epochs dans `checkpoints/`
- Contient : poids de G , poids de D , états des optimiseurs, numéro d'epoch
- Images de suivi sauvegardées tous les 5 epochs dans `outputs/images/`

5 Résultats et observations

5.1 Évolution des pertes

TABLE 2 – Évolution des pertes au cours de l'entraînement

Phase (Epochs)	Loss D (moy.)	Loss G (moy.)
1 – 25	$\approx +0.33$	≈ 3.4
25 – 150	oscillante	croissante
150 – 200	≈ -2.5	$\approx 15-25$
200 – 300	$[-3.0, +0.6]$	$[13, 48]$

5.2 Interprétation des pertes

- **Loss D négative** : comportement *normal* en WGAN-GP. La perte représente une estimation de la distance de Wasserstein (non bornée inférieurement), pas une probabilité.
- **Loss G élevée et oscillante** : indique que le générateur peine à tromper un discriminateur bien entraîné, ce qui peut signaler un début de *mode collapse* partiel.
- **Phase initiale stable** (epochs 1–25) : les pertes modérées suggèrent que les deux réseaux progressent de concert.

5.3 Résultats visuels

Les images générées sont évaluées sur une grille fixe 4×4 couvrant les 4 classes (4 exemples par classe), avec un vecteur latent fixe `fixed_z` permettant de suivre l'évolution intra-epoch.




FIGURE 1 – Gauche : images générées à l'époque 25. Droite : epoch 150.




FIGURE 2 – Gauche : images générées à l'époque 205. Droite : epoch 305.

6 Difficultés rencontrées

1. **Instabilité en seconde moitié d'entraînement** : la Loss G présente de fortes oscillations après l'époque 150, suggérant un déséquilibre entre G et D .
2. **Mode collapse partiel** : observable via l'explosion occasionnelle de la Loss G (jusqu'à 48), indiquant que G génère parfois des images peu diversifiées.
3. **Sensibilité au learning rate** : une réduction de LR de $2e-4$ à $5e-5$ a amélioré la stabilité globale de l'entraînement.

7 Pistes d'amélioration

7.1 Stabilisation de l'entraînement

- Augmenter **N_CRITIC** à 5 pour mieux contraindre le discriminateur
- Implémenter un **learning rate scheduler** (décroissance cosinus)
- Ajouter de la **spectral normalization** en complément du gradient penalty

7.2 Amélioration de la qualité

- Tester une architecture **Progressive Growing GAN** (ProGAN)
- Explorer **StyleGAN2** pour un meilleur contrôle du style
- Augmenter la résolution cible au-delà de 64×64

7.3 Évaluation quantitative

- Implémenter la métrique **FID** (Fréchet Inception Distance)
- Calculer l'**Inception Score (IS)**
- Évaluation par classification supervisée sur images synthétiques

7.4 Données

- Data augmentation (rotations, flips) pour enrichir le dataset
- Rééquilibrage des classes si déséquilibre existant

8 Conclusion

Ce projet démontre la faisabilité de la **génération conditionnelle d'images de galaxies** par WGAN-GP. Le modèle apprend à produire des images structurées conditionnées par type morphologique, avec une architecture claire et un pipeline d'entraînement robuste incluant la gestion des checkpoints.

Malgré des instabilités observées en seconde phase d'entraînement caractéristiques des GANs sur des données à forte variabilité les résultats visuels montrent une progression cohérente. Les pistes d'amélioration précisées ci-dessus, comme l'implémentation de la métrique FID, constituent des directions naturelles pour la suite de ce travail.

Un travail supplémentaire pour appliquer des transformations aux images pour simuler des lentilles gravitationnelles permettraient de travailler en amont des data release du satellite Euclid.